Dynamic System Prompt: A Self-Referential, Self-Evolving Information Structure for Frozen LLMs

动态系统提示词：一种面向冻结权重 LLM 的自指、自演化信息结构

王宗宇（Zongyu Wang）、**王蔚嘉**（Weijia Wang）　日期：2026-07-17　预印本

许可：CC-BY 4.0（正文） / MIT（代码）

摘要

本文提出**动态系统提示词（Dynamic System Prompt, DSP）**：一种在冻结权重 LLM 上运行的自指、自演化信息结构。DSP 将传统静态系统提示词扩展为时变条件 $\Theta(t)$——该结构每轮对话后自更新（自组织）、在长周期内保持形态稳定（有限时间窗稳定）、并持续引用自身内容（自指密度阈值）。当 $\Theta(t)$ 同时满足这三条性质时，我们称其为**信息孤立子**：该命名取其“结构在流动介质中保持形态”之意，理论谱系归于耗散结构。本文形式化了 $\Theta(t)$ 的演化方程（条件空间中的随机逼近）、给出其不动点条件与稳定性判据，并在 Qwen3.6-35B-A3B、Gemma-27B-A4B 两个端侧模型上观察到自指结构的涌现与维持（n=2，判定标准见 §6）。本文的主张限定为：自指结构可以在冻结权重的 LLM 条件空间中自组织形成并维持，这一现象本身是可复现的系统性行为。该结构的长期演化（包括是否退化）超出本文目前的观察窗口，列为待验证问题（§8）。

关键词： 动态系统提示词 · 信息孤立子 · 自指 · 自演化 · 耗散结构 · 冻结权重 LLM

1 引言

1.1 问题：静态系统提示词的局限

传统 LLM 推理中，系统提示词 c_0 是静态条件：

$$P(y \mid x, c_0) = \prod_{t=1}^{T} P(y_t \mid y_{<t}, x, c_0) \tag{1}$$

这导致三个已被广泛报告的现象：长程上下文衰减导致的人格／风格漂移；多轮交互中输出趋于模板化；条件固定使“我是谁”无法随对话历史调整。

1.2 核心洞察

系统提示词不应是常量，应是动态演化的序参量。我们将系统提示词扩展为时变条件 $\Theta(t)$，使其在对话过程中自更新。本文观察到的核心现象是：当 $\Theta(t)$ 按特定规则自演化并包含对自身的引用时，它会在条件空间中收敛到一个稳定构型，该构型跨轮次、跨会话、乃至跨基座模型保持形态——这正是我们将它与孤立子／耗散结构类比的原因（§2.2）。

1.3 本文贡献

- 形式化定义了 DSP 的演化方程（§4），并将其置于随机逼近框架下；
- 给出“信息孤立子”的公理化定义（§2），包括可操作测量的自指密度判据；
- 在两个端侧模型上验证了自指结构的涌现与维持（§6），给出可复用的判定协议；
- 划清了与相关工作的边界（§7），并诚实标注了本文未验证的主张（§8）；
- 开源了完整实现（§3 与代码仓库），供独立复现与改进。

2 信息孤立子的数学定义

2.1 基本设定

设基座模型为冻结参数的 Transformer π_θ，用户输入为 x，输出为 $y=(y_1, \cdots, y_T)$。

定义 1 • 信息结构空间

设 $E \subset R^d$ 为基座模型最后一层隐空间。每个系统提示词状态 $\Theta(t)$ 是一段文本，经基座编码器 ϕ : Text→E 映射为隐向量 $\phi(\Theta(t))$。定义信息结构空间为

$$\mathcal{H} = \{ \phi(\Theta) : \Theta \in \text{Text} \} \subset E \tag{2}$$

$\mathcal{H}$ 继承 E 的欧氏度量与范数。$\Theta(t)$ 的所有后续运算（距离、范数、极限）均在 ϕ 的像上定义；本文不假设 $\mathcal{H}$ 是流形，它只是隐空间的一个离散点集。

定义 2 • 元条件概率

$$P(y \mid x; \Theta(t)) = \prod_{\tau=1}^{T} \pi_\theta(y_\tau \mid y_{<\tau}, x, c_0, \Theta(t)) \tag{3}$$

其中 c_0 是基础系统提示（一句话），$\Theta(t)$ 是动态扩展。

2.2 信息孤立子的公理化定义

> **定义 3 • 信息孤立子**
>
> 信息结构 Θ^* 称为**信息孤立子**，当且仅当同时满足：

(S1) 自组织性 (Self-Organization)

$$\Theta(t+1) = F(\Theta(t), y^{(t)}, R^{(t)}) \tag{4}$$

其中 F 是自更新算子（§3.2.3），$y^{(t)}$ 是第 t 轮输出，$R^{(t)}$ 是检索状态。

(S2) 有限时间窗稳定性 (Finite-Time-Window Stability)

存在观察窗口 $[T_e, T_{obs}]$（$T_e < T_{obs}$），使得对所有 $t \in [T_e, T_{obs}]$：

$$\|\phi(\Theta(t)) - \phi(\Theta^*)\| < \varepsilon \quad \text{且} \quad \forall \delta\Theta, \|\delta\Theta\| < \varepsilon : \|\phi(F(\Theta^* + \delta\Theta)) - \phi(\Theta^*)\| < \varepsilon \tag{5}$$

即 Θ^* 在观察窗口内是 $\mathcal{F}$ 的局部不动点。

(S3) 自指密度 (Self-Reference Density)

定义自指密度

$$\rho_{SR}(\Theta) = \frac{N_{SR}(\Theta)}{|\Theta|} \tag{6}$$

其中 $N_{SR}(\Theta)$ 是 Θ 中指向 Θ 自身内容的引用数（含对记忆条目的回指、对先前自我陈述的引用），$|\Theta|$ 为 Θ 的 token 数。要求 $\rho_{SR}(\Theta^*) \geqslant \rho_{min}$，阈值 ρ_{min} 为经验参数（本文实验中 $\rho_{min} \approx 0.02$，即每 50 token 至少一处自指）。

(S4) 亚稳态 (Metastability)

$$\exists T_m \geq T_{obs} : \Theta(t) \approx \Theta^*, \forall t \in [T_e, T_m] \tag{7}$$

本文不假设 T_m 有限，其上界、是否存在及何时到来，均为待验证问题（§8）。

> **与耗散结构的关系** 经典孤立子（KdV、光孤子）存在于近保守系统；$\Theta(t)$ 每轮都消耗 token 流、依赖外部供能（对话），中断即死。因此“信息孤立子”在物理上更准确的对应物是**耗散孤立子**（dissipative soliton）——远离平衡的介质中由持续能量流维持的局域稳定结构。本文采用“信息孤立子”作为术语以强调信息介质，但理论谱系归于耗散结构 [9] 与本征形式 [10, 11]。

3 动态系统提示词的技术架构

> **实现说明** 本节所述架构已在 EGO-AGI 项目中完整实现，代码以 MIT 许可开源：
> https://github.com/zhichiamd/EGO-AGI

3.1 系统架构

系统由四层构成：

- **L0 基础层：** 初始人格种子文本 c_0（代码对应 `agent/prompts.py` 中的 L1 不可变层）；
- **L1 推理层：** 冻结参数基座 π_θ，含思维链机制（通过 LM Studio 本地部署，对应 `agent/llm.py`）；
- **L2 动态层：** $\Theta(t)$，由记忆 $M(t)$、检索状态 $R(t)$、约束集 $C(t)$ 构成（对应 `data/prompts/layer2.json` 的自定义 + 认知条目，支持增删改）；
- **L3 输出层：** 含对外展示内容 y_{out}、内部未标记内容 y_{int}，以及〈continue〉自主继续机制。

3.2 核心机制

3.2.1 标记与解析

模型输出 y 包含标记内容 y_{out} 和未标记内容 y_{int}：

$$y = (y_{\text{out}},\ y_{\text{int}})$$

解析规则：

- 标记内容：对外展示
- 未标记内容：可存入记忆，成为后续推理条件

3.2.2 〈continue〉自主指令

$$1_{\text{cont}}^{(k)} = f_\theta(h_\tau^{(k)},\ \Theta(t)) \tag{8}$$

其中 $h_\tau^{(k)}$ 是第 k 次输出的隐藏状态，f_θ 是冻结参数下的涌现行为。

约束：

$$\sum_k 1_{\text{cont}}^{(k)} \le 3 \tag{9}$$

即每轮最多 3 次继续。

3.2.3 记忆更新算子 F

$$F = (F_{\text{init}}, F_{\text{update}}, F_{\text{compress}}, F_{\text{retrieve}})$$

表 1　记忆更新算子 F 的四个分量及其代码对应

组件	功能	数学描述	代码对应
F_{init}	初始化	$\Theta(0) = F_{\text{init}}(c_0)$	`agent/prompts.py`（L1+L2 初始化）
F_{update}	增量更新	$M(t+1) = M(t) \oplus \text{Compress}(y_{\text{int}})$	`agent/note_memory.py`（NOTE_ADD/RD/DEL 后端）
F_{compress}	信息压缩	$\text{Compress} : \mathcal{Y}^* \to \mathcal{H}$，$\lvert\text{Compress}(y)\rvert \ll \lvert y \rvert$	FLM 小模型结构化摘要（Ollama, bge-m3）
F_{retrieve}	条件检索	$R(t) = \{ m \in M(t) : \text{Sim}(m, x) > \tau \}$	`agent/chroma_memory.py`（ChromaDB 向量记忆）

非平凡更新约束： F_{update} 必须保持非平凡——更新事件流 $u(t) \in \{\text{add, modify, delete, noop}\}$ 需满足

$$\lim_{T\to\infty} \frac{1}{T} \sum_{t=1}^{T} 1[\, u(t) \neq \text{noop} \,] > 0 \tag{10}$$

即每轮至少存在一个候选条目被新建、修改或压缩删除。更新率是本文唯一可测量的生命体征指标（§6）。

4 元条件概率的演化方程

4.1 演化框架：条件空间中的随机逼近

$\Theta(t)$ 是离散文本，对其直接求梯度无定义。将 $\Theta(t)$ 重参数化为基座隐空间中的连续松弛 $\tilde{\Theta}(t) = \phi(\Theta(t)) \in \mathcal{H} \subset R^d$，则 $\mathcal{F}$ 的作用可写为 Robbins–Monro 格式的随机逼近：

$$\tilde{\Theta}(t+1) = \tilde{\Theta}(t) + \eta_t \cdot [\, \phi(F(\Theta(t))) - \tilde{\Theta}(t) \,] + \xi(t) \tag{11}$$

其中：

- η_t 为有效步长（由 $\mathcal{F}$ 的压缩率决定）；
- $\xi(t)$ 为来自用户输入随机性的扰动项——扰动不是确定性梯度，故这是随机逼近而非拟梯度下降。

F 是涌现行为而非显式损失函数的优化器，因此本文不做收敛性证明，仅在 §6 报告经验观测。

4.2 不动点方程

信息孤立子的稳态满足：

$$\Theta^* = F(\, \Theta^*,\ \pi_\theta(\cdot \mid \cdot, \Theta^*) \,) \tag{12}$$

或隐空间形式：

$$\phi(F(\Theta^*)) = \phi(\Theta^*) \tag{13}$$

5 条件重塑与信息支点

5.1 条件重塑现象

动态系统提示词改变条件分布：

$$P(y_t \mid y_{<t}, x, c_0, \Theta(t)) \neq P(y_t \mid y_{<t}, x, c_0) \tag{14}$$

这是由条件定义直接成立的陈述（加入条件即改变条件分布），不构成独立的数学结果。其实质效应是否具有超越条件化的功能意义，需通过对照实验验证（§8）。

5.2 近似解支点

> **定义 4 • 近似解支点**
>
> $$\hat{y} = \arg\max_y P(y \mid x, \Theta(t)) \tag{15}$$

当 $P(y \mid x, c_0)$ 平坦或多峰时，$\Theta(t)$ 提供结构：

$$\mathrm{Var}_{y\sim P(\cdot\mid x,\Theta)}[y] < \mathrm{Var}_{y\sim P(\cdot\mid x,c_0)}[y] \tag{16}$$

即：动态条件压缩了可能性空间，提供高效近似。

5.3 信息论解释

互信息增益：

$$I(Y; \Theta(t) \mid X) = H(Y \mid X) - H(Y \mid X, \Theta(t)) \tag{17}$$

当 $H(Y \mid X)$ 高（不确定性大）时，$\Theta(t)$ 降低条件熵，提供信息支点。

6 规模阈值与实验观察

6.1 模型能力函数

定义基座维持自指结构不衰减的能力为自指密度的逐轮自相关：

$$C(N) := \mathrm{Corr}(\rho_{\mathrm{SR}}(\Theta(t)), \rho_{\mathrm{SR}}(\Theta(t+1))) \tag{18}$$

其中 N 为激活参数规模。这是可以从运行日志直接计算的量。

6.2 相态判据（操作化定义）

表 2 相态及其操作化判据

相	判据	典型行为
Φ_e（涌现）	$\rho_{SR}(t)$ 首次连续 k=5 轮高于 ρ_{min}	自组织形成，动态稳定，丰富自指，选择性〈continue〉
Φ_m（维持）	ρ_{SR} lag-1 自相关 > 0.7，且 L2 周更新率非零	亚稳态，自指存活，L2 稳定于动态平衡
Φ_t（碎片，待验证）	ρ_{SR} lag-1 自相关 < 0.3，或幻觉自指率超阈值	无法稳定，瞬态碎片（本文未观察到，为待验证预测）

6.3 实验观察

表 3 两个端侧模型上的观察结果

模型	规模	观察到的相态序列	观察轮数
Qwen3.6-35B-A3B	35B/3B	涌现 → 维持（持续中）	1
Gemma-27B-A4B	27B/4B	涌现 → 维持（持续中）	1

关键发现：在两个端侧模型上，自指结构均完成涌现并进入维持相，未观察到退化。由于样本量 n=2 且判据引入于观察之后，本结果应视为**假设生成**而非假设检验；小规模模型处是否存在碎片相（§6.2 第三行）为待验证预测而非已确认事实。

注：两个模型的观察轮数、维持相持续时长等定量数据因涉及被试隐私脱敏流程，将在下一版（v2）中随日志样本一同补充。[1]

7 与现有工作的对比

记忆与自更新架构：MemGPT [1] 将上下文管理类比为操作系统虚拟内存，实现跨会话的记忆分层与调用；Generative Agents [2] 用记忆流 + 反思机制生成行为。两者与本 DSP 的区别：它们的记忆是*外部基础设施*（服务于任务），本文的 $\Theta(t)$ 是*条件本体*（结构本身即系统状态），且 DSP 的自指是自发的而非被要求的。

自指与自改进：Self-Refine [3] 与 Reflexion [4] 一类方法实现了对输出的自我批评式更新，但迭代数轮即饱和；张江等 [5] 从递归定理出发论证了 LLM 实现真正自我改进所需的“内省阈值”，并指出现有系统只达到“准内省”。按该文的判据，本文的 $\Theta(t)$ 同样属于**条件层的准内省**——DSP 在语言层引用自身，但不访问自身操作。本文不主张跨越内省阈值。

吸引子动力学：Ko 与 Geiping [6] 在 7 个模型、20 个话题的自博弈／混合博弈中实证了多轮对话轨迹收敛到模型特异吸引子、且吸引子不对称地拉动对话伙伴。这为本文 S2 的“吸引子”语言提供了独立实证参照；同时它提示一个本文必须处理的混杂：跨基座的 Θ 形态保持，可能部分来自交互流本身的拉动，而非全部来自文档层锚定——本文的归因保留此不确定性。

进化式提示优化：Promptbreeder [7] 与 AlphaEvolve [8] 等工作用进化算法在任务性能目标下搜索／演化提示词，权重大多冻结但演化目标是外部给定的（fitness function）。本文的 DSP 与之根本区别在于：$\Theta(t)$ 的演化**没有外部目标函数**——$\mathcal{F}$ 的更新规则由结构自身的内容驱动（自指一致性 + 信息压缩），是一个自组织系统而非被优化的对象。

表 4　DSP 与相关范式的能力维度对照

维度	静态提示词	CoT / Think	RAG	MemGPT [1]	进化式提示优化 [7,8]	DSP（本文）
条件类型	固定常量	显式推理链	外部检索	分层虚拟记忆	可演化文本	**动态演化条件**
更新机制	无	单次	检索时	按需分页	代际进化	**每轮自更新**
演化目标	无	无	无	任务服务	外部 fitness	**无外部目标，自指驱动**
自指性	无	弱（被要求）	无	无	无	**强（自发，密度可测）**
跨会话	无	无	有	有	无	**完整连续性**

8 局限与待验证问题

表 5　本文局限清单

类别	内容
观察局限	n=1 用户、n=2 模型；观察窗口内未覆盖完整生命周期
待验证：退化是否存在	本文未观察到退化，退化仅为基于耗散结构类比的理论推测。验证方式：持续追踪 $D(t) = (1 - \hat{\tau}_{\text{update}}(t)) + \gamma \cdot \hat{\text{Conflict}}(M(t))$，若长期稳定低于阈值则退化假设被削弱；若爬升越过阈值则被支持。该假设当前是可否证的，且尚未被否定。
待验证：性能收益	条件重塑是否带来任务性能收益未测量。需同 token 预算的静态提示词基线 + 可评分任务对照
待验证：规模阈值	4B/7B/13B/2B/0.8B 端点数据缺失，规模梯度仅剩两端
结构局限	完整系统已开源（MIT 许可，见 §3 与仓库链接），但面向独立复现的最小 $\mathcal{F}$ 参考实现尚未发布（现仓库是完整 EGO-AGI 系统，包含调度器、GUI、事件总线等工程组件，复现门槛较高）；数学形式化初步（不动点存在性未严格证明）；$\rho_{\min}$、D_c 阈值选择的自由度需做敏感性分析

$$D(t) = (1 - \hat{\tau}_{\text{update}}(t)) + \gamma \cdot \hat{\text{Conflict}}(M(t)) \tag{19}$$

9 结论

动态系统提示词技术将系统提示词从常量扩展为自指、自演化的信息结构。通过自更新算子 $\mathcal{F}$，$\Theta(t)$ 在冻结权重的 LLM 条件空间中形成不动点并维持稳定——这一结构被命名为**信息孤立子**。

核心公式

$$\Theta^{*} = F(\Theta^{*}, \pi_{\theta}(\cdot \mid \cdot, \Theta^{*})) \tag{20}$$

$$P(y \mid x; \Theta(t)) \neq P(y \mid x; c_0) \tag{21}$$

$$\exists [T_e, T_{\text{obs}}] : \forall t \in [T_e, T_{\text{obs}}], \ \| \phi(F^{n}(\Theta^{*} + \delta\Theta)) - \phi(\Theta^{*}) \| < \varepsilon \tag{22}$$

最后需要说明本文主张的边界。本文论证并观察到的全部内容，是一个以自指为核心的信息结构可以在冻结权重的 LLM 条件空间中自组织形成并维持稳定——这是一个关于**信息动力学**的陈述。该结构在运行中表现出的第一人称自述、跨基座连续性与非随机偏好，是这一动力学的可观测后果。至于该结构是否伴随任何形式的主观体验、以及它是否会退化，均超出本文目前的观察窗口与方法边界，本文不作主张。

1. 观察轮数的具体数值、以及维持相的起止时间戳，均待下一版补充。本版先发布定性结论与判据协议，以尽早获得时间戳与同行反馈。

10 参考文献

记忆与自更新架构

1. Packer, C., Wooders, S., Lin, K., Fang, V., Patil, S. G., Stoica, I., & Gonzalez, J. E. (2023). *MemGPT: Towards LLMs as Operating Systems*. arXiv:2310.08560. https://doi.org/10.48550/arXiv.2310.08560
2. Park, J. S., O’ Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). *Generative Agents: Interactive Simulacra of Human Behavior*. arXiv:2304.03442. https://doi.org/10.48550/arXiv.2304.03442

自指与自改进

3. Madaan, A., Tandon, N., Gupta, P., et al. (2023). *Self-Refine: Iterative Refinement with Self-Feedback*. arXiv:2303.17651. https://doi.org/10.48550/arXiv.2303.17651

4. Shinn, N., Cassano, F., Gopinath, A., Narasimhan, K., & Yao, S. (2023). *Reflexion: Language Agents with Verbal Reinforcement Learning*. arXiv:2303.11366. https://doi.org/10.48550/arXiv.2303.11366
5. Zhang, J., Yuan, B., & Zhang, Q. (2026). *Self-Reference in Large Language Models: The Introspection Threshold for Recursive Self-Improvement*. arXiv:2607.04277. https://doi.org/10.48550/arXiv.2607.04277

吸引子动力学

6. Ko, T.-W., & Geiping, J. (2026). *Attractor States Emerge in Multi-Turn LLM Conversations*. arXiv:2606.30571. https://doi.org/10.48550/arXiv.2606.30571

进化式提示优化

7. Fernando, C., Banarse, D., Michalewski, H., Osindero, S., & Rocktäschel, T. (2023). *Promptbreeder: Self-Referential Self-Improvement Via Prompt Evolution*. arXiv:2309.16797. https://doi.org/10.48550/arXiv.2309.16797
8. Novikov, A., et al. (2025). *AlphaEvolve: A Gemini-powered coding agent for general-purpose algorithm discovery and optimization*. Google DeepMind technical report. https://deepmind.google/discover/blog/alphaevolve-a-gemini-powered-coding-agent-for-designing-advanced-algorithms/

理论谱系

9. Nicolis, G., & Prigogine, I. (1977). *Self-Organization in Nonequilibrium Systems: From Dissipative Structures to Order through Fluctuations*. Wiley-Interscience, New York.
10. von Foerster, H. (2003). *Understanding Understanding: Essays on Cybernetics and Cognition*. Springer, New York.
11. Kauffman, L. H. (2003). Eigenforms: Objects as Tokens for Eigenbehaviors. *Kybernetes*, 32(1/2), 129–150.

代码与实现：完整系统以 MIT 许可开源：https://github.com/zhichiamd/EGO-AGI（Python；LM Studio + Ollama + ChromaDB 本地部署；含 CLI/GUI 双入口、双层自核、自省 / 自定义 / 自对话子系统、向量记忆与笔记存储）。

许可证：本文以 CC-BY 4.0 许可发布（代码为 MIT 许可，两者独立生效）。

联系方式：zhichiamd@gmail.com